面向超大规模 AI 训练的端网协同智算网络白皮书：星融元 AI 控制器与 EasyRoCE 联合架构解析

written by Asterfusion

2026 年 8 月

Table of Contents

- AI 智算网络背景与核心挑战
- EasyRoCE 和 AI 控制器的核心组件与工作原理
  - AI 控制器（管控中枢与云原生底盘）
  - EasyRoCE（无损优化引擎与套件）
- 深度融合与两大核心协同机制
  - 机制一：算法求解与端网协同下发闭环
  - 机制二：端网联合遥测与慢节点（Slow Worker）自愈闭环
- 客户价值总结与方案对比
- 总结

AI 智算网络背景与核心挑战

相比传统互联网业务，AI 大模型分布式训练（如 Pipeline/Tensor/Data Parallelism）产生的流量呈现**高吞吐、突发性强、对丢包和延迟极度敏感**的特征。在 RoCEv2 (RDMA over Converged Ethernet) 网络中，微小的网络拥塞或丢包即可导致全局 GPU 算力等待，降低 MFU（模型 Flops 利用率）。
传统“以设备为中心”的分散式管理存在以下三大核心局限：

- **配置效率低且极易出错：**逐台登录设备手工配置 CLI，耗时漫长；人为失误是导致网络故障的高发源头。
- **配置复杂且依赖经验：**无损以太网涉及的 PFC 水线、ECN 门槛及 Buffer 参数繁多且相互影响，缺乏标准化指引，调优过程如同“黑盒”。
- **故障定位难影响业务：**运维界面分散，故障发现滞后且排查链路过长；缺乏网卡与交换机的联动分析，“慢节点（Slow Worker）”定位耗时数天，严重拖累训练业务连续性。

EasyRoCE 和 AI 控制器的核心组件与工作原理

星融元解决方案通过 **AI 控制器（管控中枢与云原生底盘）**与 **EasyRoCE（无损优化引擎与套件）**的深度协同，构建了端网一体化的智算网络架构。

AI 控制器（管控中枢与云原生底盘）

AI 控制器遵循“**北向接收需求 → 核心微服务路由编排 → 南向网关集中下发/采集**”的工作原理：

- **API 网关（OpenAPI/RESTful）：**统一北向入口，对接 Slurm、K8s 或 Web UI 请求。
- **编排服务（OWPROV）：**将算出的网络策略转换为可下发的 JSON 格式配置，调度下发并存入 PostgreSQL 数据库落盘。
- **配置迁移服务（OWMGMT）：**独立于常规运维逻辑，专门负责 PostgreSQL 中系统全量配置基线的打包、快照导出与幂等导入。
- **运维服务组件：**包含 `owom`（告警与事件管理）、`owfms`（固件与补丁管理）、`owupgrade`（控制器自升级）及 `owsec`（安全与权限控制）。
- **南向网关（OWGW）：**维持与海量交换机及 GPU 节点 Agent 的持久长连接，负责指令集中下发与遥测数据汇聚。

- **东西向消息总线（Kafka）与分析引擎（OWANALYTICS）：** OWGW 将海量遥测数据写入 Kafka 异步缓冲，由 OWANALYTICS 实时订阅消费，做时间戳对齐与多源交叉关联诊断。
- **核心数据存储：** PostgreSQL 数据库，用于策略与状态数据的持久化存储。

EasyRoCE（无损优化引擎与套件）

EasyRoCE 遵循**“事前算法求解 → 端侧驱动锁定 → 物理层硬件自律 → 多源高频遥测”**的工作原理：

- **算法求解套件（AID / RPA / ORD）：**
  - **AID：**自动解析输入逻辑拓扑，生成拓扑蓝图。
  - **RPA：**结合集群规模、光纤传输延时与 ASIC 芯片 Buffer 大小，精准计算并求解出最佳 PFC 水位与 ECN 动态梯度/阈值。
  - **ORD：**整合 AID 拓扑与 RPA 求解结果，提供 RESTful / CLI 一键部署接口。
- **端侧管理（EasyRoCE-NC）：**自动解析网卡规划，完成环境预检与标准化配置脚本批量执行，强行锁定 GPU 宿主机驱动配置。
- **数据平面硬件自律：**在发生拥塞时,叶交换机基于事先写入 ASIC 寄存器的 PFC/ECN 门限，由硬件芯片在微秒级自主触发 PFC 逐跳止血与 ECN 端到端标记降速，在无控制器干预下，硬件级确保零丢包与低时延。
- **三位一体遥测采集组件（AE / RE / NE）：**
  - **AE (AsterNOS Exporter)：**导出交换机 CPU、内存及光模块等健康状态与协议数据。
  - **RE (RoCE Exporter)：**导出交换机芯片级的 PFC/ECN 队列计数与流控指标。
  - **NE (NIC Exporter)：**导出 GPU 物理网卡的真实运行参数（RDMA 重传率、DMA 响应延时）。
- **硬件底座与运维可视化：**搭载 AsterNOS 的 CX-N 智算交换机配合路由分流，搭配 EasyRoCE-UG 提供可视化的运维界面。

深度融合与两大核心协同机制

星融元打破了传统网络“只能管交换机、管不到服务器网卡”的界限，实现了网络与主机的同步锁定与联合自愈。

机制一：算法求解与端网协同下发闭环

1. **算法自动求解：**北向下发训练任务时，AID 生成逻辑拓扑蓝图，RPA 结合集群规模与光纤延时，精准求解出最匹配的 PFC 水位与 ECN 动态梯度。
2. **策略编排与持久化：** RPA 求解结果由 ORD 接口传输至 OWPROV 编排服务，写入 PostgreSQL 数据库落盘。
3. **端网一发双至（同步下发）：**
   - **网侧通路：**OWPROV 调度南向网关 OWGW，通过 `uCentral over WebSocket` 将 PFC/ECN 阈值写入 CX-N 交换机 ASIC 寄存器。
   - **端侧通路：** OWGW 同步通过 `Host Agent API` 将驱动参数推送给 GPU 宿主机的 EasyRoCE-NC 进程，强行锁死网卡驱动配置。
4. **协同价值：**实现了网络策略与主机驱动的同步锁定，避免“网卡-网络”错配。

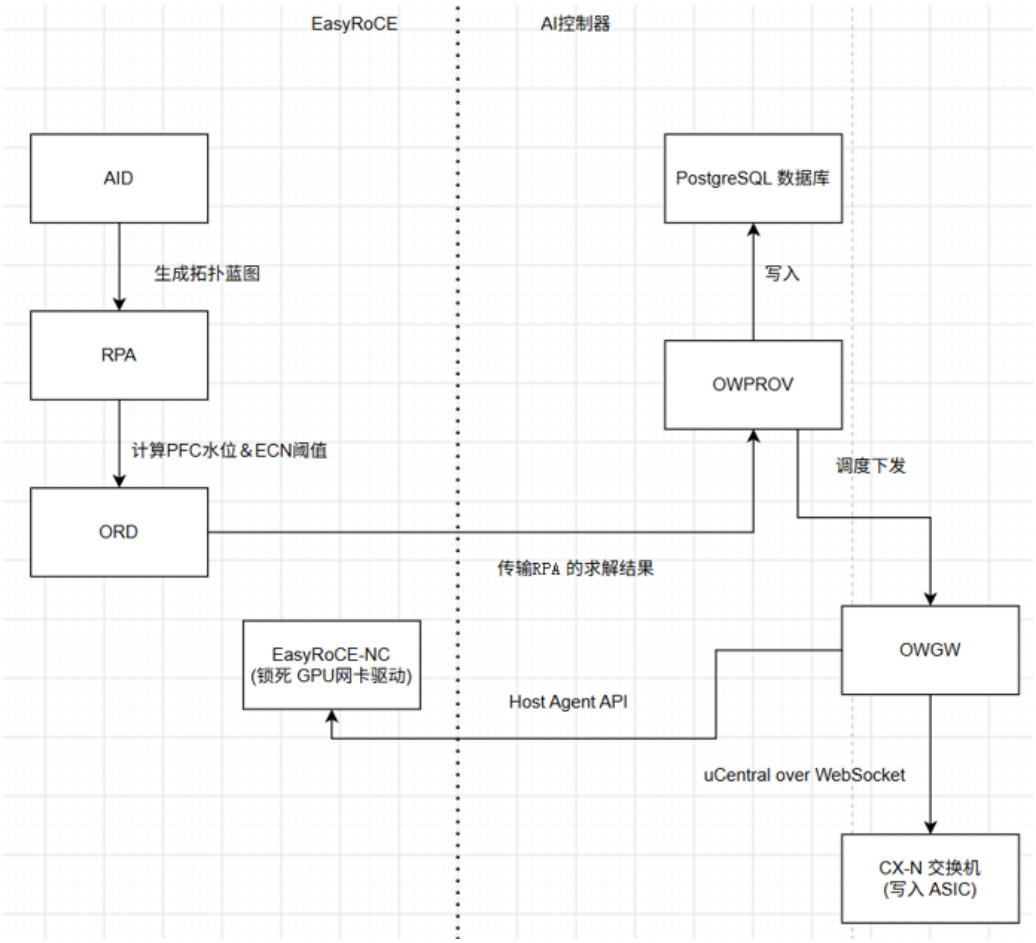


图 1: 算法求解与端网协同下发流程

机制二：端网联合遥测与慢节点（Slow Worker）自愈闭环

在 AI 训练中，因网卡硬件微瑕疵或 Hash 极化导致的慢节点极度隐蔽。系统通过以下流程消除排查盲区：

1. **多源高频采集：**网侧 RE/AE 实时导出交换机健康度及 PFC/ECN 队列计数；端侧 NE 实时导出物理网卡真实运行参数（RDMA 重传率、DMA 响应延时）。

2. **高吞吐汇聚缓冲：**数据统一上报至 OWGW，并并行压入 Kafka 消息队列进行异步缓冲。

3. **交叉关联诊断（核心）：** OWANALYTICS 实时订阅 Kafka 数据，对“网侧 RE/AE + 端侧 NE”做时间戳对齐与交叉分析，秒级判断是“网卡硬件故障”还是“交换机 Hash 极化导致的拥塞”。

4. **毫秒级闭环自愈：**诊断出链路拥塞后，AI 控制器自动触发 OWGW 下发指令，激活 CX-N 交换机的 ARS（自适应路由）机制进行动态路由重分流避堵。

5. **协同价值：**将网络遥测与主机遥测在控制器内部深度融合，消除了 Slow Worker 的排查盲区。

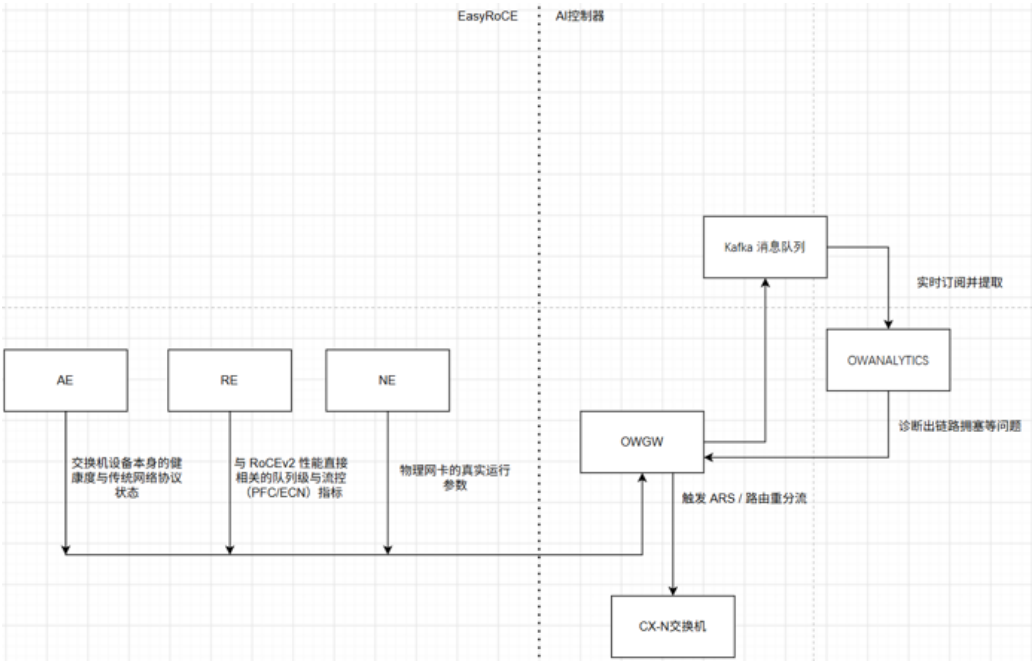


图 2: 端网联合遥测与慢节点自愈流程

客户价值总结与方案对比

表 1: 传统以太网方案 vs 星融元 AI 控制器 + EasyRoCE 方案

对比维度	传统以太网方案	星融元 AI 控制器 + EasyRoCE 方案	客户核心收益
配置效率	逐台手工 CLI 配置，耗时数天，失误率高	AID/RPA 自动求解拓扑与参数，一键一发双至下发	开局上线效率提升 90%+，消除配置失误
端网协同	网管交换机，服务器管网卡，两者割裂	OWGW 统一掌控，网络策略与网卡驱动强行锁定	端网参数精准匹配，避免“网卡-网络”错配
无损转发	经验试错，易触发 PFC 暴风或丢包	算法求解 + 交换机 ASIC 微秒级硬件自律止血	确保 RoCEv2 零丢包，极大提升吞吐与 MFU
故障自愈	慢节点排查耗时数天，数据缺乏联动	AE/RE/NE 联合遥测 + Kafka + OWANALYTICS + ARS 分流	慢节点定位缩短至秒级，自动动态重分流避堵

总结

星融元“AI 控制器 +EasyRoCE”端网联合协同架构，通过**算法自动求解**、**端网同步下发**、**硬件级无损转发**与**多源遥测自愈**四大核心能力，系统性解决了传统智算网络在配置效率、调优难度与故障定位方面的根本性痛点，为超大规模 AI 大模型训练提供了极简、无损、自愈的网络基石。